



CSIC 2010 데이터셋 규모별 EDA 비교 분석 보고서

1. 서론

머신러닝 및 딥러닝 기반의 웹 방화벽(WAF)이나 침입 탐지 시스템(IDS)을 구축하기 전, 데이터의 특성을 파악하는 EDA(Exploratory Data Analysis) 단계는 모델의 성능과 신뢰성을 결정짓는 핵심적인 과정입니다.

본 보고서는 동일한 환경에서 추출되었으나 데이터 규모가 다른 두 개의 분석 결과(10,000건의 샘플 데이터 및 61,065건의 전체 데이터)를 심층 비교합니다. 데이터 크기가 약 6배 이상 증가함에 따라 데이터의 분포, 극단치(Outlier), 그리고 통계적 파라미터가 어떻게 변화하는지 정밀하게 분석하여, 향후 모델 학습 및 연구 시 고려해야 할 핵심 인사이트를 도출하는 것을 목적으로 합니다.

2. 본론

2.1. 데이터 규모 및 클래스 균형(Class Balance) 차이

두 데이터셋의 가장 명확한 차이는 데이터 총량이며, 이에 따른 클래스별 분포는 다음과 같습니다.

비교 항목	10K 데이터셋 (csic2010_requests.csv)	61K 데이터셋 (csic2010_requests60000.csv)	차이 및 분석
총 데이터 건수	10,000건	61,065건	약 6.1배 데이터 증가
정상 (Normal)	5,895건 (약 58.95%)	36,000건 (약 58.95%)	비율이 완벽히 일치함
공격 (Anomalous)	4,105건 (약 41.05%)	25,065건 (약 41.05%)	클래스 불균형 정도가 동일하게 유지



통계적 인사이트:

데이터가 6만 건으로 대폭 확장되었음에도 불구하고 정상과 공격 데이터의 비율이 소수점 둘째 자리까지 일치한다는 점은 매우 고무적입니다. 이는 1만 건의 샘플 데이터가 6만 건의 전체 모집단(Population)을 매우 정교하게 반영하는 **계층적 무작위 추출(Stratified Random Sampling)** 방식으로 설계되었음을 입증합니다.

2.2. URL 및 Body 길이(Length) 통계량의 미세한 변화

요청 데이터의 길이는 악성 여부를 판단하는 중추적인 피처입니다. 데이터 규모 확장에 따른 기술 통계량 변화는 다음과 같습니다.

[URL 길이 통계]

- **공격 (Anomalous):** 평균 73.0 (유지) / 중앙값 32.0 → 34.0 (증가) / 최대값 637 → 641 (증가)
- **정상 (Normal):** 평균 50.0 → 48.0 (감소) / 중앙값 29.0 → 28.0 (감소) / 최대값 328 (유지)

[Body 길이 통계]

- **공격 (Anomalous):** 평균 47.0 → 45.0 (감소) / 중앙값 0.0 (유지) / 최대값 604 → 611 (증가)
- **정상 (Normal):** 평균 20.0 (유지) / 중앙값 0.0 (유지) / 최대값 287 → 299 (증가)

💡 통계적 인사이트:

평균(Mean)과 중앙값(Median)이 데이터 크기 증가에도 불구하고 안정적인 수치를 보이는 현상은 통계학의 **대수의 법칙(Law of Large Numbers)**으로 명쾌하게 설명됩니다. 표본의 크기 n 이 커질수록 표본 평균 $\bar{X}$ 는 모집단의 평균 μ 에 수렴하게 됩니다.

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| > \epsilon) = 0$$

다만, 주목해야 할 변화는 **최대값(Max)의 증가**입니다. 데이터 규모가 커짐에 따라 더욱 길고 복잡한 페이로드(예: 대규모 SQL Injection 쿼리, 난독화된 스크립트 등)를 포함한 **극단치(Edge Case)**가 추가로 관측되었습니다. 이는 모델의 일반화 능력을 키우는 데 핵심적인 역할을 합니다.

2.3. 키워드 분포 및 핵심 발견의 일관성

두 규모의 데이터셋 분석 결과는 공통적으로 다음과 같은 4가지 핵심 패턴을 도출했습니다.

1. **길이의 유의미성:** 공격 요청의 URL은 정상 요청보다 평균적으로 긴 경향을 보입니다.
2. **특정 키워드 집중:** SQL, XSS, Path Traversal 관련 특수 문자 및 키워드가 공격 데이터에 밀집되어 있습니다.
3. **라벨링 특성:** 개별 공격 유형이 아닌 정상/공격의 이진 분류(Binary Classification) 구조를 가집니다.
4. **학습 데이터의 시간적 특성:** 1교시(First Session) 학습 패턴이 데이터 상에서 명확히 확인됩니다.

2.4. 추가 검증을 위한 코드 가이드 (Python Pandas)

예성님께서 향후 프로젝트 진행 시 두 데이터셋의 분포 차이를 직접 프로그래밍 방식으로 검증하실 수 있도록 최적화된 코드를 제공합니다.

```
import pandas as pd
import numpy as np

# 데이터 로드
df_10k = pd.read_csv("csic2010_requests.csv")
df_61k = pd.read_csv("csic2010_requests60000.csv")

def compare_datasets(df1, df2, col_name):
    """두 데이터셋의 특정 컬럼 길이에 대한 통계량 비교"""
    stats1 = df1[col_name].apply(len).agg(['mean', 'median', 'max'])
    stats2 = df2[col_name].apply(len).agg(['mean', 'median', 'max'])

    comparison = pd.DataFrame({
        '10K_Sample': stats1,
        '61K_Full': stats2,
        'Diff': stats2 - stats1
    })
    return comparison

print("--- URL 길이 통계 비교 ---")
print(compare_datasets(df_10k, df_61k, 'url'))
```

3. 결론

두 규모의 EDA 시각화 결과를 대조 분석한 결과, 10,000건의 샘플 데이터는 61,065건의 전체 데이터를 통계적으로 매우 훌륭하게 대변하는 **양질의 표본(Representative Sample)**임이 입증되었습니다.

[학습 및 연구 전략 제언]

- **프로토타이핑 단계:** 알고리즘 선정 및 하이퍼파라미터 튜닝 시에는 리소스 소모가 적고 특성이 안정적인 **10K 데이터셋**을 활용하는 것이 연구 효율성 측면에서 우수합니다.
- **최종 모델링 단계:** 실제 환경에 배포할 모델을 구축할 때는 61K 데이터셋에서 새롭게 발견된 '**확장된 극단적 공격 패턴(Increased Max Length)**'까지 학습할 수 있도록 반드시 전체 데이터셋을 사용해야 합니다.

본 보고서는 데이터 과학적 방법론에 근거하여 작성되었습니다. 연구 및 프로젝트의 목적에 맞춰 활용하시기 바랍니다.